هوشمندسازی حرکت مسیر یک ربات چهارپای ماه‌نورد برمبنای طراحی حلقه‌های کنترل به روش یادگیری تقویتی

سپهر ماه‌فر[۱]، علیرضا شریفی[۲*]
۱- کارشناسی مهندسی هوافضا، دانشگاه صنعتی شریف، sepehr.mahfar81@sharif.edu
۲- هیئت علمی دانشکده مهندسی هوافضا، دانشگاه صنعتی شریف، ar.sharifi@sharif.edu
*علیرضا شریفی

چکیده

هدف از انجام این پژوهش، هوشمندسازی حرکت یک ربات چهارپای ماه‌نورد دوازده‌درجه‌آزادی با استفاده از کنترل به روش یادگیری تقویتی است. به‌این‌منظور، ابتدا، از فرمت توصیف رباتیک یکپارچه (URDF) یک ربات چهارپا برای شبیه‌سازی ساختار فیزیکی، مفاصل، حسگرهای ربات در محیط شبیه‌ساز آیزاک جیم (Isaac Gym)، که دارای سرعت پردازشی بالا به‌دلیل وجود واحد پردازش گرافیکی (GPU) است، استفاده می‌شود. سپس، فرامین سرعت توسط حلقه هدایت برمبنای منطق تناسبی-انتگرالی-مشتقی (PID) با دریافت موقعیت چهارپا و نیز با تنظیم زاویه سمت ربات به سیستم کنترل چهارپا ارسال می‌شود. در گام بعد، کنترل‌کننده مبتنی بر یادگیری تقویتی (RL) فرمان موقعیت‌زاویه‌ای مفاصل ربات را با استفاده از مقدار مطلوب سرعت مستخرج از حلقه هدایت و نیز عامل بهینه‌سازی سیاست مجاورتی (PPO)، که سیاست‌های بهینه را از طریق تعامل با محیط فرا می‌گیرد، صادر می‌کند. در گام بعد، فرمان گشتاور مورد نیاز هر مفصل با استفاده از منطق کنترل‌کننده تناسبی-مشتقی (PD) برمبنای موقعیت‌زاویه‌ای مطلوب، که از بخش یادگیری تقویتی حاصل شده است، صادر می‌شود. در نهایت، ربات چهارپا می‌تواند یک مسیر مشخص را در محیط شبیه ساز آیزاک جیم تعقیب می‌کند؛ که نسبت به اغتشاشات خارجی مقاوم است.

واژه های کلیدی: هدایت مسیر- ربات چهارپا- ماه‌نورد- کنترل هوشمند- یادگیری تقویتی

۱- مقدمه

در سال‌های اخیر، ربات‌های چهارپا [۱] به دلیل توانایی بالا در پیمایش مسیرهای ناهموار و دامنه حرکتی گسترده، مورد توجه بسیاری قرار گرفته‌اند. توانایی ربات‌های چهارپا در پیمایش مسیرهای ناهموار منجر به استفاده از این ربات‌ها در پیمایش زمین‌های ناهموار سیاره‌ها و ماه در محیط‌هایی که ربات‌های چرخ دار قابل استفاده نیستند، شده‌است.

اولین ربات متحرک و کنترل‌شونده از راه دور که روی یک جرم آسمانی دیگر فرود آمد، Lunokhod 1 (به معنی «ماه‌نورد») [۲] بود. این ربات توسط فضاپیمای Luna 17 به ماه منتقل شد، فضاپیمای که در تاریخ ۱۰ نوامبر ۱۹۷۰ توسط اتحاد جماهیر شوروی پرتاب شد. در شکل ۱، تصویر این ربات مشاهده می‌شود:

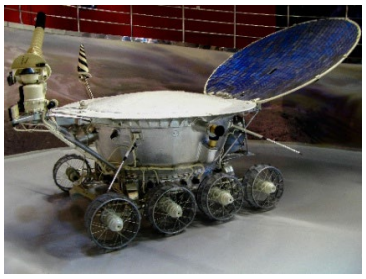

شکل۱-. Lunokhod 1 (منبع: ویکی پدیا)

باتوجه به محدودیت‌های ربات‌های چرخ‌دار در پیمایش زمین‌های ناهموار، استفاده از ربات‌های چهارپا به‌منظور پیمایش سطح ماه در سالیان اخیر، بسیار مورد توجه واقع‌شده است[۳]. در شکل ۲، تصویر ربات یک ربات چهارپا (Anymal) اصلاح‌شده به‌منظور پیمایش سطح ماه، مشاهده می‌شود:

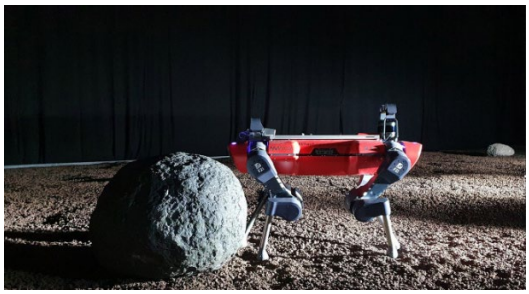

شکل۲-. ربات چهارپای Anymal

با وجود کارآیی بالا، استفاده از این ربات‌ها تا به امروز به دلیل پیچیدگی دینامیک و دشواری کنترل آن‌ها محدود بوده است. در گذشته، تلاش زیادی برای کنترل و هدایت ربات‌های چهارپا با استفاده از کنترل‌کننده‌های کلاسیک [۴] و یا حتی کنترل‌کننده‌های مدرن [۵] [۶] صورت گرفته‌است. طراحی کنترل‌کننده‌ای که بتواند ضمن حفظ تعادل ربات، فرامین کنترلی سرعت را به موقعیت زاویه‌ای مفاصل تبدیل کند و هم‌چنین طراحی یک حلقه هدایت که بتواند فرامین کنترلی موقعیت را به فرامین کنترلی سرعت تبدیل کند و این ربات‌ها را به‌صورت موزون و به‌مانند حیوانات از مبدأ به مقصد برساند، چالشی جذاب و ارزشمند به شمار می‌رود. ربات چهارپا دوازده درجهٔ آزادی (مفصل) دارد. نحوه حرکت این ربات‌ها مبتنی بر اعمال گشتاور بر هر یک از مفاصل و حرکت پاها به‌نتیجهٔ آن است. اولین گام به‌منظور اعمال فرامین موقعیت به ربات، طراحی کنترل‌کننده‌ای است که بتواند فرامین کنترلی سرعت را به موقعیت زاویه‌ای مفاصل تبدیل کند. معرفی الگوریتم گرادیان سیاست قطعی عمیق (DDPG) [۷] در سال 2015، استفاده از یادگیری تقویتی را به منظور کنترل سیستم‌هایی با فضای کنش پیوسته ممکن ساخت. این رویکرد دریچه‌های جدیدی را برای کنترل سیستم‌های پیچیده گشود. از زمان معرفی الگوریتم DDPG تا کنون، الگوریتم‌های جدیدتری با هدف بهبود عملکرد و کاهش حجم محاسبات برای پیاده‌سازی یادگیری تقویتی معرفی شده‌اند. بهینه‌سازی سیاست مجاور (PPO) [۸] یکی از جایگزین‌ها برای الگوریتم DDPG می‌باشد که به دلیل تولید سیاست‌های مقاوم، سادگی تنظیم هایپرپارامترها و سادگی پردازش موازی بسیار مورد توجه واقع شده‌است. با در نظر گرفتن موارد ذکر شده، یک کنترل‌کننده مبتنی بر یادگیری تقویتی با استفاده از عامل PPO در نقش کنترل‌کننده اولیه طراحی شده که فرامین کنترلی سرعت را به موقعیت زاویه‌ای مفاصل تبدیل می‌کند. سپس، موقعیت زاویه‌ای مفاصل وارد یک کنترل‌کنندهٔ تناسبی-مشتقی شده و میزان گشتاور مورد نیاز برای رساندن هر مفصل به موقعیت زاویه‌ای محاسبه شده توسط کنترل‌کننده

اول، به دست می‌آید. در گام بعد، یک حلقه هدایت با هدف تبدیل فرامین کنترلی موقعیت به فرامین کنترلی سرعت ایجاد می‌شود. در این رویکرد ، ربات با تنظیم زاویه سمت خود و حرکت در راستای محور x بدنی به موقعیت مطلوب می‌رسد. سیستم کنترلی حلقه بسته ربات چهارپا در شکل ۳ نشان داده شده‌است.

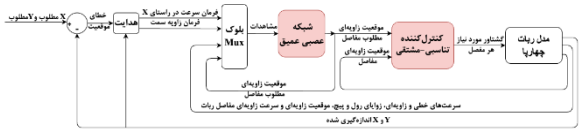

شکل۳-. سیستم کنترلی حلقه بسته ربات چهارپا

هوشمندسازی حرکت ربات چهارپای ماه‌نورد شامل گام‌های زیر است: الف) توسعه مدل دینامیکی متناسب با شبیه‌ساز مورد استفاده، ب) پیاده‌سازی فرآیند یادگیری تقویتی در شبیه‌ساز به‌منظور تعقیب فرامین سرعت خطی و زاویه‌ای مطلوب، ج) تکمیل حلقه هدایت به‌جهت تولید فرامین سرعت مناسب در راستای تعقیب فرامین موقعیت مطلوب.

این پژوهش در هفت بخش اصلی تنظیم شده‌است. در بخش دوم به مدل دینامیکی ربات چهارپا . نحوه کارکرد اشاره می‌شود. در بخش سوم کنترل‌کننده طراحی‌شده به‌منظور تبدیل فرامین کنترلی سرعت خطی و زاویه‌ای به موقعیت زاویه‌ای مطلوب مفاصل و هم‌چنین کنترل‌کننده مورد استفاده جهت تولید گشتاور مورد نیاز مفاصل برای رساندن مفاصل به موقعیت زاویه‌ای مطلوب بررسی می‌شود. در بخش چهارم به نحوه کارکرد حلقه هدایت طراحی‌شده به‌منظور تعقیب فرامین موقعیت مطلوب پرداخته می‌شود. در بخش پنجم عملکرد حلقه هدایت و کنترلی طراحی‌شده در رسیدن به موقعیت مطلوب و هم‌چنین تعقیب موج سینوسی در دو وضعیت الف) شرایط ایده‌ال و ب) وجود نویز در سنسورها و عملگر و هم‌چنین وارد شدن اغتشاش خارجی به ربات بررسی می‌شود. در بخش ششم و هفتم نیز به جمع‌بندی پژوهش و مرجع‌های مورد استفاده در آن پرداخته می‌شود.

۲- مدل دینامیکی ربات چهارپا

برای شبیه‌سازی مدل ربات چهارپا از فایل URDF استفاده می‌شود. فایل URDF شامل تمامی مشخصه‌های فیزیکی ربات از جمله تمامی قطعات، اتصالات، مفاصل و محل اتصال آن‌ها، محدودیت‌های فیزیکی (برای مثال بیشینه زاویه چرخش مفاصل)، جرم و ممان اینرسی قطعات و ... است.

۲-۱- دستگاه مختصات اینرسی

دستگاه اینرسی مورداستفاده در شبیه‌سازی در مرکز و دقیقا بر روی سطح زمین قرار گرفته به‌گونه‌ای که محور z آن به سمت بالا باشد. دستگاه مختصات اینرسی در شکل ۴ نمایش داده شده‌است. خط قرمز محور x، خط سبز محور y و خط آبی محور z دستگاه مختصات اینرسی را نشان می‌دهد.

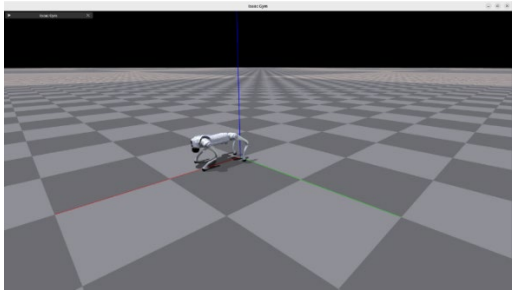

شکل۴-. دستگاه مختصات اینرسی

۲-۲- دستگاه مختصات بدنی

سرعت و وضعیت ربات باتوجه به سرعت و وضعیت تنه آن نسبت به اینرسی سنجیده می‌شود. دستگاه مختصات بدنی تنه ربات بر روی مرکز جرم آن قرار دارد. مطابق شکل ۵ محور x به سمت جلوی تنه (خط قرمز)، محور y به سمت چپ تنه (خط سبز) و محور z این دستگاه نیز به سمت بالای تنه (خط آبی) قرار گرفته‌است.

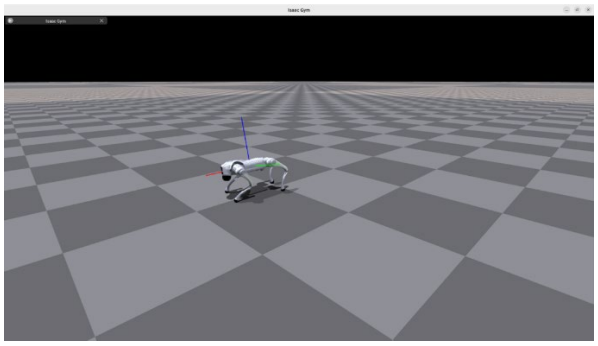

شکل۵-. دستگاه مختصات بدنی

۲-۳- موقعیت‌های زاویه‌ای قراردادی مفاصل

منظور از موقعیت زاویه‌ای قراردادی، موقعیت زاویه‌ای هر یک از مفاصل در زمانی که هیچ گشتاوری به آن‌ها وارد نمی‌شود، است.

۳- طراحی کنترل‌کننده

در سیستم کنترلی طراحی شده، از دو کنترل‌کننده استفاده شده‌است. کنترل‌کننده اول موقعیت زاویه‌ای هر یک از مفاصل را در راستای دنبال کردن فرامین کنترلی سرعت محاسبه کرده و کنترل‌کننده دوم نیز، وظیفه دارد میزان گشتاور مورد نیاز برای رسیدن هر یک از مفاصل به موقعیت زاویه‌ای مطلوب محاسبه کند. این ساختار منجر به تشکیل یک حلقه کنترلی بسته می‌شود و به دلیل گرفتن بازخورد از موقعیت زاویه‌ای هر یک از مفاصل، از رسیدن آن‌ها به موقعیت زاویه‌ای مطلوب، مطمئن می‌شود.

۳-۱- کنترل‌کننده اول

کنترل‌کننده اول، یک شبکه عصبی عمیق است. مشاهدات به عنوان ورودی وارد شبکه عصبی عمیق شده و موقعیت زاویه‌ای مطلوب هر یک از مفاصل به منظور دنبال کردن فرامین کنترلی سرعت توسط شبکه عصبی محاسبه می‌شود. در این پژوهش، مشاهدات شامل سرعت‌های خطی و زاویه‌ای ربات، موقعیت و سرعت زاویه‌ای مفاصل ربات، زاویه رول و پیچ ربات، فرامین کنترلی و اقدامات صورت گرفته توسط عامل در گام زمانی قبلی می‌باشد.

در این پژوهش برای پیاده‌سازی فرآیند یادگیری تقویتی، از الگوریتم PPO-Clip مبتنی بر ساختار منتقد-عامل استفاده می‌شود. عامل به سیاست $\pi_\theta(a|s)$ که θ در آن نشان‌دهنده پارامترهای سیاست است اشاره دارد. منظور از منتقد نیز تابع ارزش $V_\phi(s)$ است که ϕ در آن نشان‌دهنده پارامترهای تابع ارزش است. سیاست $\pi_\theta(a|s)$ یک توزیع احتمال بر روی عمل‌ها در یک حالت مشخص s است. هدف یادگیری پارامترهای θ که منجر به بیشینه شدن بازگشت مورد انتظار می‌شوند، است.

تابع هدف الگوریتم PPO-Clip، $L^{Clip}(\theta)$ به صورت زیر تعریف می‌شود:

$$L^{Clip} = \mathbb{E}_t\left[\min\left(r_t(\theta)A_t, \text{clip}\left(r_t(\theta), 1-\varepsilon, 1+\varepsilon\right)A_t\right)\right] \quad (۱)$$

$r_t(\theta)$ در عبارت فوق نسبت احتمال بین سیاست جدید و سیاست قدیم است و به صورت زیر محاسبه می‌شود:

$$r_t(\theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \quad (۲)$$

ε نیز یک فراپارامتر است که مقدار آن معمولا کوچک است. این فراپارامتر مشخص می‌کند که سیاست جدید تا چه میزان اجازه دارد از سیاست قبلی دور شود. A_t نیز تخمین‌گر مزیت تعمیم‌یافته است. این تابع، مزیت انجام کنش a در وضعیت s را در قیاس با پاداش مورد انتظار میانگین برای آن وضعیت تحت سیاست فعلی را محاسبه می‌کند. این تابع به ارزیابی میزان بهتر یا بدتر بودن یک عمل نسبت به عملکرد متوسط آن در یک حالت خاص کمک می‌کند. در این رویکرد، مزیت به‌عنوان تفاوت بازگشت اعمال و تخمین تابع ارزش تعریف می‌شود. تخمین تابع ارزش، $(Q^\pi(s,a))$، بازگشت مورد انتظار در صورتی که مسیر $R(\tau)$ از حالت s شروع شده، یک کنش دلخواه a (که ممکن است از سیاست π نباشد) انجام شود و سپس برای همیشه طبق سیاست π عمل شود، خروجی می‌دهد:

$$Q^\pi(s,a) = \mathbb{E}_{\tau\sim\pi}\left[R(\tau)\,|\,s_0 = s, a_0 = a\right] \quad (۳)$$

با استفاده از مفهوم فوق، تابع تخمین مزیت به‌صورت زیر تعریف می‌شود:

$$A_t = \delta_t + (\gamma\lambda)\delta_{(t+1)} + (\gamma\lambda)^2\delta_{(t+2)} + \cdots \quad (۴)$$

در عبارت فوق، γ و λ به ترتیب فاکتور تنزیل و پارامتر هموارسازی هستند. پارامتر هموارسازی تخمین مزیت را در طول زمان را با کمک تعدیل بازگشت‌های زمان کوتاه و زمان بلند هموار می‌کند. با تنظیم پارامتر هموارسازی می‌توان میزان اثرگذاری پاداش‌های زودهنگام را در برابر پاداش‌های زمان‌های دورتر در زمان محاسبه تابع مزیت کنترل کرد. δ_t نیز خطای اختلاف موقت است که به صورت زیر محاسبه می‌شود:

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) \quad (۵)$$

فرآیند بهینه‌سازی شامل تکرار بر روی دسته‌ای از داده‌ها، اعمال گرادیان صعودی و بیشینه کردن تابع هدف است. جمع‌آوری داده‌ها توسط تعاملات ربات با محیط و ذخیره‌سازی تحولات در یک حافظه موقت (Buffer) صورت انجام می‌شود. هر گام بهینه‌سازی بین نمونه‌برداری بسته‌های کوچک از حافظه موقت و بروزرسانی سیاست و تابع ارزش به‌صورت متناوب انجام می‌شود. به منظور استفاده کامل از اطلاعات هر بسته، چند دوره (Epoch) بروزرسانی بر روی یک دسته از داده مشخص اعمال می‌شود. شیوه بروزرسانی پارامترهای سیاست در هر گام بهینه‌سازی به‌صورت زیر است:

$$\theta_{k+1} = \arg\max_\theta \mathop{\mathbb{E}}_{s,a\sim\pi_{\theta_k}}\left[L(s,a,\theta_k,\theta)\right] \quad (۶)$$

PPO علاوه‌بر بروزرسانی سیاست، تابع ارزش را نیز را به منظور افزایش دقت در تخمین بازگشت مورد انتظار بروزرسانی می‌کند. زیان تابع ارزش به‌عنوان میانگین خطای مربعی بین بازگشت‌های واقعی و بازگشت‌های پیش‌بینی شده محاسبه می‌شود:

$$L^{VF}(\phi) = \mathbb{E}_t\left[\left(R_t - V_\phi(s_t)\right)^2\right] \quad (۷)$$

برای تشویق الگوریتم به اکتشاف و جلوگیری از همگرایی ناپخته به سیاست‌های زیربهینه از امتیاز آشفتگی استفاده می‌شود:

$$H\left(\pi_\theta(a_t|s_t)\right) = -\sum_a \pi_\theta(a|s)\log\pi_\theta(a|s) \quad (۸)$$

علامت منفی مطمئن می‌شود که عدم قطعیت بیش‌تر منجر به ارزش مثبت برای آشفتگی شود. در نظر گرفتن احتمالات مساوی برای اقدام‌های مختلف توسط سیاست $\pi_\theta(a|s)$ به معنای اکتشافی بودن سیاست است که منجر به بالا بودن آشفتگی می‌شود. بالا بودن آشفتگی عملگر را به اکتشاف اقدام‌های متفاوت می‌کند. این موضوع در مراحل اولیه یادگیری که عملگر نیاز به جمع‌آوری تجربه‌های متنوع از محیط دارد، بسیار مهم است. درنهایت، تابع هدف کل به صورت زیر محاسبه می‌شود:

$$\begin{aligned} L^{total}(\theta) = \\ & L^{CLIP}(\theta) - c_1 L^{VF}(\phi) \\ & + c_2\mathbb{E}_t\left[H\left(\pi_\theta(a_t|s_t)\right)\right] \end{aligned} \quad (۹)$$

در عبارت فوق c_1 و c_2 به‌ترتیب فاکتور وزنی برای ارزش زیان و امتیاز آشفتگی هستند. این رویکرد منجر به عملکرد تصادفی سیاست در آموزش‌های اولیه و همگرایی تدریجی به یک رفتار قطعی می‌شود.

برای پیاده‌سازی فرآیند یادگیری تقویتی از محیط شبیه‌ساز یادگیری تقویتی آیزاک جیم استفاده می‌شود. مزیت این محیط شبیه‌ساز تولید تعداد بسیار زیاد نمونه از ربات است. این موضوع پردازش موازی محاسبات با کارت گرافیک را ممکن می‌کند و سرعت فرآیند جمع‌آوری داده را به طرز چشم‌گیری افزایش می‌دهد. هم‌چنین به منظور ساده‌سازی فرآیند آماده‌سازی محیط برای پیاده‌سازی یادگیری، از محیط لگد جیم (legged_gym) [۹] که برای پیاده‌سازی فرآیند یادگیری ربات‌های چهار پا در آیزاک جیم ساخته‌شده استفاده می‌شود. این محیط با استفاده از کتابخانه rsl_rl، فرآیند آماده‌سازی محیط را ساده‌تر می‌کند.

به‌منظور تولید سیاستی که بتواند فرامین کنترلی سرعت را به موقعیت زاویه‌ای مطلوب هر یک از مفاصل تبدیل کند، تعداد زیادی پاداش و مجازات مقیاس‌شده متناسب با ارزش، با یکدیگر جمع شده و تابع پاداش کامل را تشکیل می‌دهند. این پاداش‌ها و مجازات‌ها شامل پاداش برای تعقیب سرعت زاویه‌ای مطلوب در راستای محور z بدنی و سرعت خطی مطلوب در راستای محور x و y بدنی، مجازات ایجاد هرگونه سرعت زاویه‌ای در راستای محور x و y بدنی، مجازات تولید گشتاور توسط موتورها، مجازات ایجاد شتاب‌زاویه‌ای در مفاصل، مجازات نزدیک شدن به آستانه موقعیت زاویه‌ای مفاصل، مجازات برخورد با زمین و پاداش برای برداشتن گام‌های بلند است. تابع پاداش تعریف‌شده عامل را به پیدا کردن سیاست بهینه با مصرف انرژی کمینه تشویق می‌کند. در این رویکرد، پاداش سرعت خطی و زاویه‌ای به‌صورت نمایی درنظر گرفته می‌شود:

$$\text{Reward } v_{xy} = e^{\frac{-Error\, v_{xy}}{0.25}} \quad (۱۰)$$

$$\text{Reward } \omega_z = e^{\frac{-Error\, \omega_z}{0.25}} \quad (۱۱)$$

در این پژوهش هر دو شبکه عصبی منتقد و عملگر سه لایه پنهان دارند. در هر دوی آن‌ها لایه اول ۵۱۲، لایه دوم ۲۵۶ و لایه سوم نیز ۱۲۸ گره دارد. به‌دلیل تعداد بسیار زیاد نمونه برای جمع‌آوری داده در محیط آیزاک جیم، حداکثر تعداد گام زمانی کوچک انتخاب می‌شود. برای این پژوهش در هر قسمت به‌ازای هر نمونه ربات حداکثر ۲۴ گام زمانی طی می‌شود. در شکل ۶، تصویر معماری شبکه عصبی و ورودی‌ها و خروجی‌های آن مشاهده می‌شود:

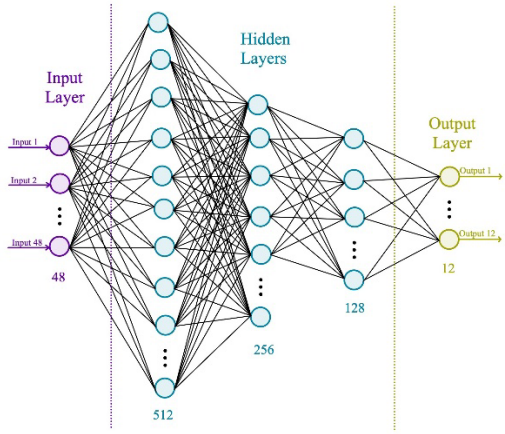

شکل۶-. معماری شبکه عصبی آموزش داده‌شده

بهینه‌ساز در این پژوهش از نرخ یادگیری تطبیقی مبتنی بر واگرایی KL استفاده می‌کند. واگرایی KL بین سیاست فعلی و سیاست قدیمی در زمان آموزش محاسبه می‌شود. سپس با در نظر گرفتن یک آستانه مشخص، نرخ یادگیری تنظیم می‌شود:

$$D_{KL}\left(N\left(\mu_1,\sigma_1^2\right)\middle\|N\left(\mu_2,\sigma_2^2\right)\right) = \log\left(\frac{\sigma_2}{\sigma_1}\right)+\frac{\sigma_1^2+\left(\mu_1-\mu_2\right)^2}{2\sigma_2^2}-0.5 \qquad (۱۲)$$

منظور از σ و μ در معادله فوق، به‌ترتیب میانگین و انحراف معیار توزیع اقدام‌های سیاست است.

پس از محاسبه ضریب KL، نرخ یادگیری با در نظر گرفتن یک آستانه مشخص تنظیم می‌شود:

$$\text{Learning Rate} = \begin{cases} \dfrac{\text{Default Learning Rate}}{1.5} & \text{if KL} > \text{Desired KL*2} \\ \text{Default Learning Rate}*1.5 & \text{if KL} < \text{Desired } \dfrac{\text{KL}}{2} \end{cases} \qquad (۱۳)$$

هم‌چنین به‌منظور مقاوم‌سازی سیاست تولید شده نسبت به پدیده‌های تصادفی دنیای واقعی، ضریب اصطکاک سطح در بازه ۰/۵ تا ۱/۲۵ و به‌صورت تصادفی انتخاب می‌شود. هم‌چنین مشاهدات با نویزهای تصادفی جمع می‌شوند تا فضای خالی بین محیط شبیه‌ساز و دنیای واقعی کاهش یابد. علاوه بر موارد مذکور، به‌جهت مقاوم‌سازی سیاست نسبت به اغتشاشات خارجی، عامل حین دوره آموزش با اغتشاشاتی در قالب سرعتی خطی با اندازه حداکثر ۱ متر برثانیه در جهات مختلف در صفحه xy روبه‌رو می‌شود.

۳-۲- کنترل‌کننده دوم

کنترل‌کننده دوم یک کنترل‌کننده تناسبی-مشتقی است. موقعیت زاویه‌ای مطلوب مفاصل که توسط شبکه عصبی محاسبه شده‌است به همراه بازخورد موقعیت زاویه‌ای هر یک از مفاصل ربات وارد کنترل کننده تناسبی-مشتقی می‌شود. سپس این کنترل‌کننده میزان گشتاور مورد نیاز برای هر مفصل به منظور رساندن آن مفصل از موقعیت زاویه‌ای فعلی‌اش به موقعیت زاویه‌ای مطلوب را محاسبه می‌کند. سازوکار کنترل‌کننده تناسبی-مشتقی استفاده شده بر اساس استفاده از خطای موقعیت زاویه‌ای هر یک از مفاصل و رساندن آن به صفر است. این رویکرد برای تمام ۱۲ مفصل ربات چهارپا به صورت مستقل دنبال می‌شود. موقعیت زاویه‌ای مطلوب مفاصل از جمع کنش تولیدشده توسط سیاست با اندازه زاویه قراردادی محاسبه می‌شود.

۴- طراحی حلقه هدایت

ربات چهارپا با استفاده از کنترل‌کننده‌های طراحی شده می‌تواند فرامین کنترلی سرعت در راستای محور x و y بدنی و فرمان کنترلی سرعت زاویه‌ای در راستای محور z بدنی (و یا زاویه سمت) را دنبال کند. در راستای طراحی حلقه هدایت (به منظور تبدیل فرامین کنترلی موقعیت به فرامین کنترلی سرعت) ربات با حرکت در راستای محور x بدنی و تنظیم زاویه سمت خود به‌سوی هدف حرکت می‌کند.

۴-۱- تنظیم سرعت خطی در راستای x بدنی

به منظور تنظیم سرعت خطی در راستای x بدنی، از منطق تناسبی-انتگرالی-مشتقی استفاده می‌شود. باتوجه به ناتوانی ربات در دنبال کردن سرعت‌های بسیار بالا درصورت تولید فرمان سرعت با اندازه بزرگتر از ۲ متر بر ثانیه، اندازه آن به مقدار ۲ متر بر ثانیه محدود می‌شود.

۴-۲- تنظیم زاویه سمت

به منظور تنظیم زاویه سمت، در گام اول باید زاویه سمت مطلوب رو مشخص کرد:

$$\psi_{\text{Desired}} = \arctan\left(\frac{y_d - y_m}{x_d - x_m}\right) \qquad (۱۴)$$

منظور از x_d و y_d در عبارت فوق به‌ترتیب موقعیت x مطلوب و y مطلوب و هم‌چنین منظور از x_m و y_m نیز به‌ترتیب موقعیت x اندازه‌گیری شده و y اندازه‌گیری شده در محیط شبیه‌ساز آیزاک جیم است. پس از مشخص شدن زاویه سمت مطلوب، با استفاده از منطق تناسبی-مشتقی و خطای زاویه سمت مطلوب محاسبه‌شده و زاویه سمت اندازه‌گیری شده ربات در محیط شبیه‌ساز آیزاک جیم، سرعت زاویه‌ای مطلوب در راستای رسیدن به زاویه سمت مطلوب را محاسبه می‌شود.

۵- نتایج شبیه‌سازی

به‌منظور ارزیابی عملکرد کنترل‌کننده و حلقه هدایت طراحی‌شده، فرامین کنترلی در حالت‌های مختلف در قالب ورودی به ربات داده شده و عملکرد ربات در محیط شبیه‌ساز آیزاک جیم شبیه‌سازی شده و ارزیابی می‌شود.

۵-۱- رسیدن به موقعیت مطلوب

در این بخش، موقعیت x مطلوب ۲۰ متر و موقعیت y مطلوب نیز ۱۰ متر درنظر گرفته می‌شود. ربات از یک نقطه تصادفی شروع به حرکت می‌کند و خود را موقعیت مطلوب می‌رساند. سپس از عملکرد ربات دو حالت ایده‌آل و حضور نویز و اغتشاش بررسی می‌شود.

در شکل ۷، نمودار موقعیت x ربات نسبت به زمان و در شکل ۸ نمودار موقعیت y ربات نسبت به زمان در محیط ایده‌آل نشان داده می‌شود:

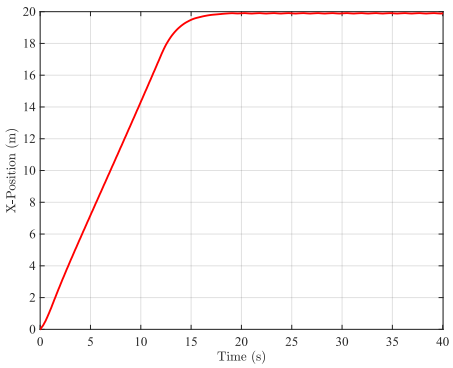

شکل۷-. نمودار موقعیت x ربات نسبت به زمان درمحیط ایده‌آل

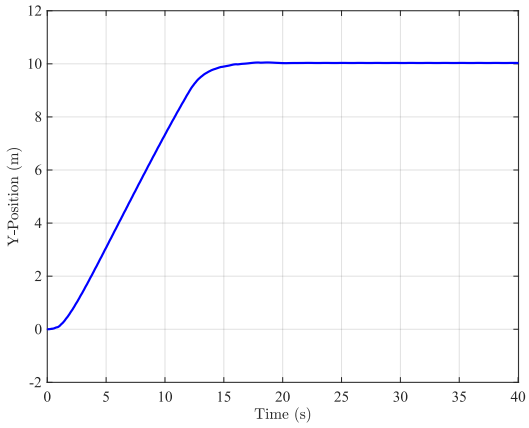

شکل۸-. نمودار موقعیت y ربات نسبت به زمان درمحیط ایده‌آل

در حالت دیگر بر تمامی مشاهدات ربات به صورت متناسب نویز اعمال می‌شود. ضریب اصطکاک سطح زمین نیز به صورت تصادفی تغییر می‌کند. هم‌چنین در طی بازه‌های ۱۵ ثانیه‌ای، به ربات در راستاهای مختلف سرعت خطی با مقدار ۱ متر بر ثانیه اعمال می‌شود. در شکل ۹ نمودار موقعیت x ربات نسبت به زمان و در شکل ۱۰ نمودار موقعیت y ربات نسبت به زمان در این حالت نشان داده می‌شود:

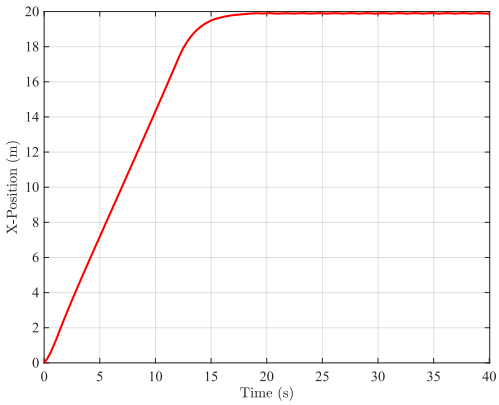

شکل۹-. نمودار موقعیت x ربات نسبت به زمان درمحیط واقعی

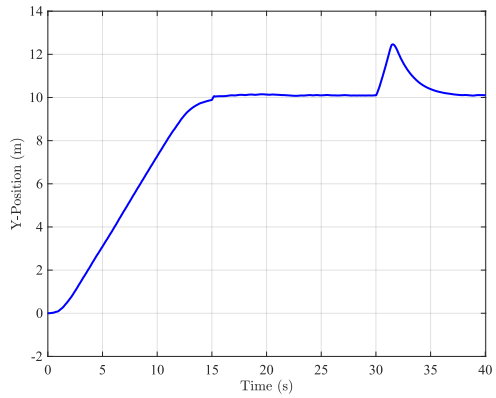

شکل۱۰-. نمودار موقعیت x ربات نسبت به زمان درمحیط واقعی

در ثانیه‌های ۱۵ و ۳۰، ربات با اغتشاش خارجی روبه‌رو می‌شود که ضمن حفظ تعادل خود، به موقعیت‌های مطلوب می‌رسد.

در شبیه‌سازی دیگر، ربات در حالت ایده‌ال مسیر سینوسی مشخص‌شده به عنوان مطلوب را دنبال می‌کند. هدف در این حالت ایجاد یک مسیر به‌شکل موج سینوسی با دامنه یک متر و دوره تناوب 4π است. به این منظور موقعیت x مطلوب به صورت خطی و متناسب با زمان به ربات داده می‌شود. ورودی y مطلوب نیز در قالب سینوس موقعیت x مطلوب به ربات داده می‌شود. سپس عملکرد ربات در با رویکرد اول هدایت در محیط شبیه‌ساز آیزاک جیم ارزیابی می‌شود. خروجی این شبیه‌سازی در شکل ۱۱ مشاهده می‌شود:

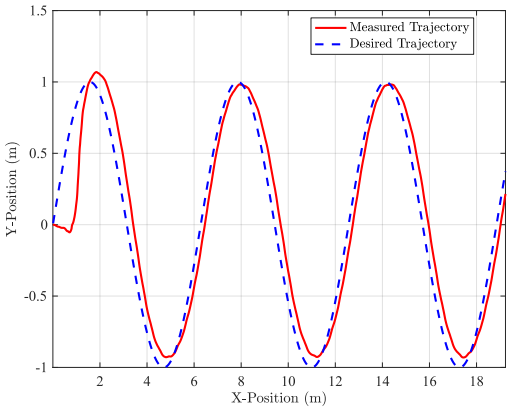

شکل۱۱- دنبال کردن مسیر سینوسی در محیط ایده‌آل

در حالتی دیگر، بر تمامی مشاهدات ربات به صورت متناسب نویز اعمال می‌شود. ضریب اصطکاک سطح زمین نیز به صورت تصادفی تغییر می‌کند. هم‌چنین در ثانیه ۱۵، به ربات در اغتشاش در قالب سرعت خطی با مقدار ۱ متر بر ثانیه اعمال می‌شود. خروجی این شبیه‌سازی نیز در شکل ۱۲ مشاهده می‌شود:

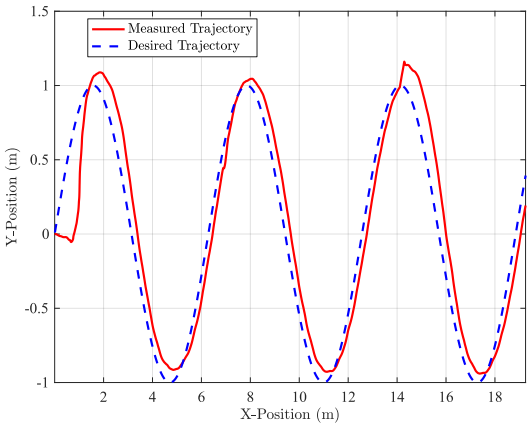

شکل۱۲- دنبال کردن مسیر سینوسی در محیط ایده‌آل

مطابق شکل ۱۲ ربات باز هم موفق به تعقیب موج سینوسی با دقت بسیار بالایی می‌شود. در ثانیه ۱۵ اغتشاش به‌صورت تقریبی در راستای حرکت ربات بوده و باعث انحراف جزئی ربات می‌شود ولی ربات تعادل خود را حفظ کرده و مسیر را ادامه می‌دهد.

۶- نتیجه‌گیری

در گزارش حاضر نحوه استفاده از یادگیری تقویتی برای کنترل ربات چهارپا و هم‌چنین طراحی حلقه هدایت برای آن شرح داده‌شد و عملکرد

حلقه کنترلی طراحی شـده در محیط آیزاک جیم مورد ارزیابی قرار گرفت. تعقیب موفق موج سـینوسـی، اسـتفاده از الگوریتم‌های طراحی مسـیر که مبتنی بر تولید نقطه راه هستند را در آینده ممکن می‌کند.

۷- مراجع

[1] JT Manter, “The dynamics of quadrupedal walking,” *Journal of Experimental Biology*, vol. 15, no. 4, pp. 571–574, May 1973.

[2] Bogue, R, "Robots for space exploration", Industrial Robot, Vol. 39 No. 4, pp. 323-328, 2012.

[3] JiangBo Zhao, Shicheng Ma, Shanshuai Niu and Junzheng Wang, “Fractional-order Virtual Model Control for Trotting Motion of Quadruped Robot,” in *2020 Chinese Control And Decision Conference (CCDC)*, Hefei, China, 2020, pp. 4935–4942.

[4] Julia Richter, Hendrik Kolvenbach, Giorgio Valsecchi, Marco Hutter, “Multi-Objective Global Path Planning for Lunar Exploration With a Quadruped Robot”, in *IEEE conference iSpaRo 2024*.

[5] Jared Di Carlo, Patrick M. Wensing, Benjamin Katz, Gerardo Bledt and Sangbae Kim, “Dynamic Locomotion in the MIT Cheetah 3 Through Convex Model-Predictive Control,” in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Madrid, Spain, 2018, pp. 7440–7447.

[6] Gerardo Bledt, Matthew J. Powell, Benjamin Katz, Jared Di Carlo, Patrick M. Wensing and Sangbae Kim, “MIT Cheetah 3: Design and Control of a Robust, Dynamic Quadruped Robot,” in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Spain, 2018, pp. 2245–2252.

[7] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver and Daan Wierstra, “Continuous control with deep reinforcement learning” in *ICLR 2016.*

[8] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. and Klimov, O, *Proximal policy optimization algorithms*. arXiv preprint arXiv:1707.06347, 2017.

[9] Nikita Rudin, David Hoeller, Philipp Reist and Marco Hutter, *Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning*. in *2021 Conference on Robot Learning (CoRL)*, 2021.